3. Podstawowe metody klasyfikacji

[52]:
```
library(yaml)
library(corrplot)
library(ggplot2)
library(reshape2)
library(MASS)
library(class)

# Global options
options(repr.plot.width = 12, repr.plot.height = 12)
```

3.1 Wczytywanie konfiguracji (*config.yaml*):

[2]:
```
config <- yaml.load_file("../config.yaml")

train_filepath <- file.path("..", config$paths$data_train)
test_filepath <- file.path("..", config$paths$data_test)
```

3.2 Przygotowanie danych

Omawiany dotychczas zbiór posiada numeryczną zmienną docelową - `elo`. Można jednak w prosty sposób przystosować ten sam zbiór do pracy z algorytmami klasyfikacji, stosując podział wartości zmiennej docelowej na dwie grupy, które będą stanowiły zarazem dwie osobne klasy.

W tym przypadku celem będzie predykcja czy dany gracz posiada ranking powyżej pewnego pułapu, a punktem podziału będzie wartość **2000 elo** rankingu - powyżej tej wartości wyróżniamy klasę pozytywną (1), a poniżej - negatywną (0).

Dla celów tej analizy wczytujemy także zbiór testowy z pliku *test.csv*.

[3]:
```
data_train <- read.csv(train_filepath)
data_test <- read.csv(test_filepath)

# Add new target variable and remove the old one
# - NOTE: we treat an exact rating of 2000 elo as "Above 2000" since it is more␣
↪intuitive approach
data_train$elo_category <- factor(ifelse(data_train$elo >= 2000, "Above 2000",␣
↪"Below 2000"))
data_train$elo_category <- factor(data_train$elo_category, levels = c("Below␣
↪2000", "Above 2000"))  # Important! Repair factor levels!
data_train$elo <- NULL

data_test$elo_category <- factor(ifelse(data_test$elo >= 2000, "Above 2000",␣
↪"Below 2000"))
data_test$elo_category <- factor(data_test$elo_category, levels = c("Below␣
↪2000", "Above 2000"))  # Important! Repair factor levels!
data_test$elo <- NULL
```

```
cat("\nPrzykładowe elementy zbioru:")
head(data_train, 5)
```

```
Przykładowe elementy zbioru:
```

A data.frame: 5 × 16

	name	games	avg_moves	frac_nonterm	avg_cp_loss	avg_inacc
	<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	astrolfos	11	31.54545	0.5454545	64.03458	1.636364
2	barbarik77	10	35.00000	1.0000000	81.44857	1.800000
3	FawkingAwesome	10	29.10000	0.7000000	110.08935	2.500000
4	ZeNNgiLy	10	28.40000	0.5000000	102.34859	2.100000
5	lelouch_VV	10	44.50000	0.5000000	68.60674	2.600000

Możemy od razu wyrzucić też kolumny `name` i `games`, które nie są istotne dla zadania klasyfikacji.

[4]:
```
data_train$name <- NULL
data_train$games <- NULL

data_test$name <- NULL
data_test$games <- NULL
```

3.3 Badanie korelacji między zmiennymi

[13]:
```
# - target variable: id 14
cor_matrix <- cor(data_train[-14])

corrplot(cor_matrix,
         method = "color",
         type = "upper",
         col = colorRampPalette(c("blue", "white", "red"))(200),
         tl.col = "black",    # kolor etykiet (czarny)
         tl.cex = 1.2,        # rozmiar etykiet
         addCoef.col = "black",  # kolor współczynników
         number.cex = 1.2)    # rozmiar liczb korelacji
```

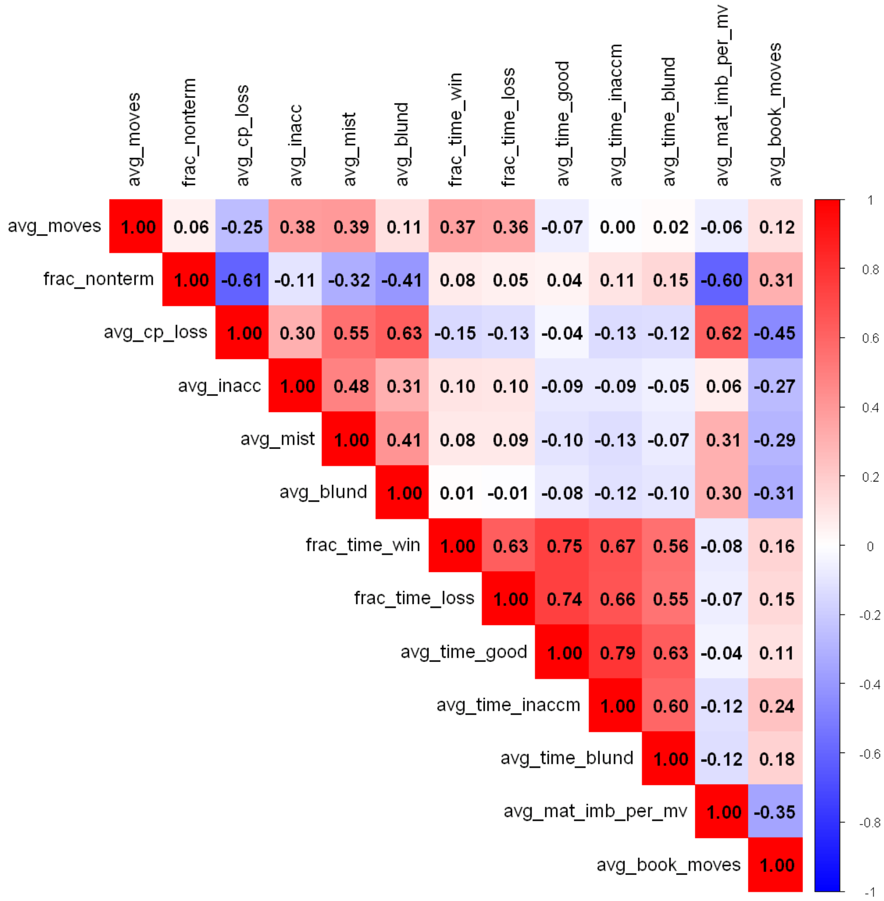

Na podstawie powyższej wizualizacji korelacji pomiędzy zmiennymi możemy wyciągnąć kilka interesujących wniosków: - Liczba ruchów jest ujemnie skorelowana ze średnią stratą w centypionach ($c = -0.25$). Oznacza to, że z reguły dłuższe partie są spokojniejsze i stosunek liczby błędów do wszystkich ruchów jest niższy (czym niższa średnia strata w centypionach, tym większa w uśrednieniu precyzja gry danego gracza). - Średnia strata w centypionach, a także ilość błędów różnej skali, jest ujemnie skorelowania z liczbą ruchów książkowych ($c = -0.45$) - co potwierdza, iż znajomość teorii prowadzi do mniejszej liczby błędów, lub też po prostu do pozycji, które są przez graczy lepiej rozumiane. - Nierównowaga materialna jest dodatnio skorelowana z poważnymi błędami ($c = 0.30$), ale nie wykazuje wyraźnej korelacji z drobnymi niedokładnościami ($c = 0.06$). Świadczy to o tym, że powstanie dużej nierównowagi materialnej zazwyczaj związane jest z pojawieniem się poważnego błędu którejś ze stron. - Odsetek partii kończących się rezygnacją którejś ze stron lub zgodą na remis (a nie np. matem) jest ujemnie skorelowany z ilością błędów różnej skali ($c < -0.11$), co świadczy o tym, że partie kończące się matem grane są na niższej dokładności niż partie kończące się w sposób wcześniej opisany. Może to sugerować, iż gracze słabsi mniej chętnie zgadzają się na poddanie lub zremisowanie partii.

3.4 Regresja logistyczna

Zaczynamy od regresji logistycznej z wykorzystaniem wszystkich istotnych cech:

[14]:
```
dir_logistic <- list()
dir_logistic$fit <- glm(elo_category ~ .,
                        family = binomial, data = data_train)

summary(dir_logistic$fit)
```

```
Call:
glm(formula = elo_category ~ ., family = binomial, data = data_train)

Coefficients:
                    Estimate Std. Error z value Pr(>|z|)
(Intercept)         0.823247   0.581100   1.417 0.156569
avg_moves           0.149163   0.013090  11.396  < 2e-16 ***
frac_nonterm       -0.315722   0.306235  -1.031 0.302550
avg_cp_loss        -0.037021   0.005182  -7.144 9.07e-13 ***
avg_inacc          -0.293872   0.083021  -3.540 0.000401 ***
avg_mist           -0.258941   0.101762  -2.545 0.010941 *
avg_blund          -1.690007   0.112379 -15.038  < 2e-16 ***
frac_time_win      -0.087178   0.412478  -0.211 0.832612
frac_time_loss      1.438923   0.346014   4.159 3.20e-05 ***
avg_time_good      -0.213638   0.035903  -5.950 2.68e-09 ***
avg_time_inaccm     0.013347   0.011115   1.201 0.229840
avg_time_blund      0.031058   0.006329   4.907 9.23e-07 ***
avg_mat_imb_per_mv -0.888175   0.051501 -17.246  < 2e-16 ***
avg_book_moves      0.622754   0.047093  13.224  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 8783.8  on 10000  degrees of freedom
Residual deviance: 4555.8  on  9987  degrees of freedom
AIC: 4583.8

Number of Fisher Scoring iterations: 7
```

Widzimy, iż większośc zmiennych okazała się być istotna statystycznie. Szczególnie istotna jest zmienna `avg_blund` oznaczająca średnią ilość krytycznych błędów popełnianych przez gracza. Współczynnik -1.690007 oznacza, iż wzrost liczby takich błędów wyraźnie zmniejsza prawdopodobieństwo, że dany gracz ma powyżej 2000 elo rankingu.

Inną bardzo istotną zmienną jest `avg_cp_loss`. Zmiana średniej straty w centypionach danego gracza o 10 w dół powoduje powoduje zmianę prawdopodobieństwa w modelu:

$$\log\left(\frac{1-p}{p}\right) = \beta_0 + \sum_{i=1}^{n} \beta_i x_i$$

powoduje zmianę *log-odds* o $\Delta = -0.037021 \times 10 = -0.37021$, co oznacza zwiększenie prawdopodobieństwa klasy pozytywnej (powyżej 2000 elo) o $e^{-0.37021} \approx 0.690$, czyli około 69%. Precyzja i kontrola w grze danego gracza jest więc decydującym czynnikiem w predykcji, czy dysponuje on rankingiem powyżej 2000.

W następnym kroku dokonujemy predykcji za pomocą utworzonego modelu regresji logistycznej:

[15]:
```
# Calculate probabilities and make predictions
dir_logistic$probs <- predict(dir_logistic$fit, type = "response")
dir_logistic$predicted <- ifelse(dir_logistic$probs > 0.5, "Above 2000", "Below␣
↪2000")

# Create confusion matrix
dir_logistic$cm <- table(dir_logistic$predicted, data_train$elo_category)
```

[16]:
```
# A helper function for visualizing confussion matrices in elegant way
plot_confusion_heatmap <- function(cm) {
  # Convert to data.frame for ggplot2 compatibility
  cm_df <- as.data.frame(as.table(cm))
  colnames(cm_df) <- c("True", "Predicted", "Freq")

  ggplot(cm_df, aes(x = Predicted, y = True, fill = Freq)) +
    geom_tile(color = "white") +
    geom_text(aes(label = Freq), size = 8) +
    scale_fill_gradient(low = "white", high = "steelblue") +
    labs(title = "Macierz pomyłek", x = "Przewidziana klasa", y = "Rzeczywista␣
↪klasa") +
    theme_minimal(base_size = 20)
}
```

[17]:
```
plot_confusion_heatmap(dir_logistic$cm)
```

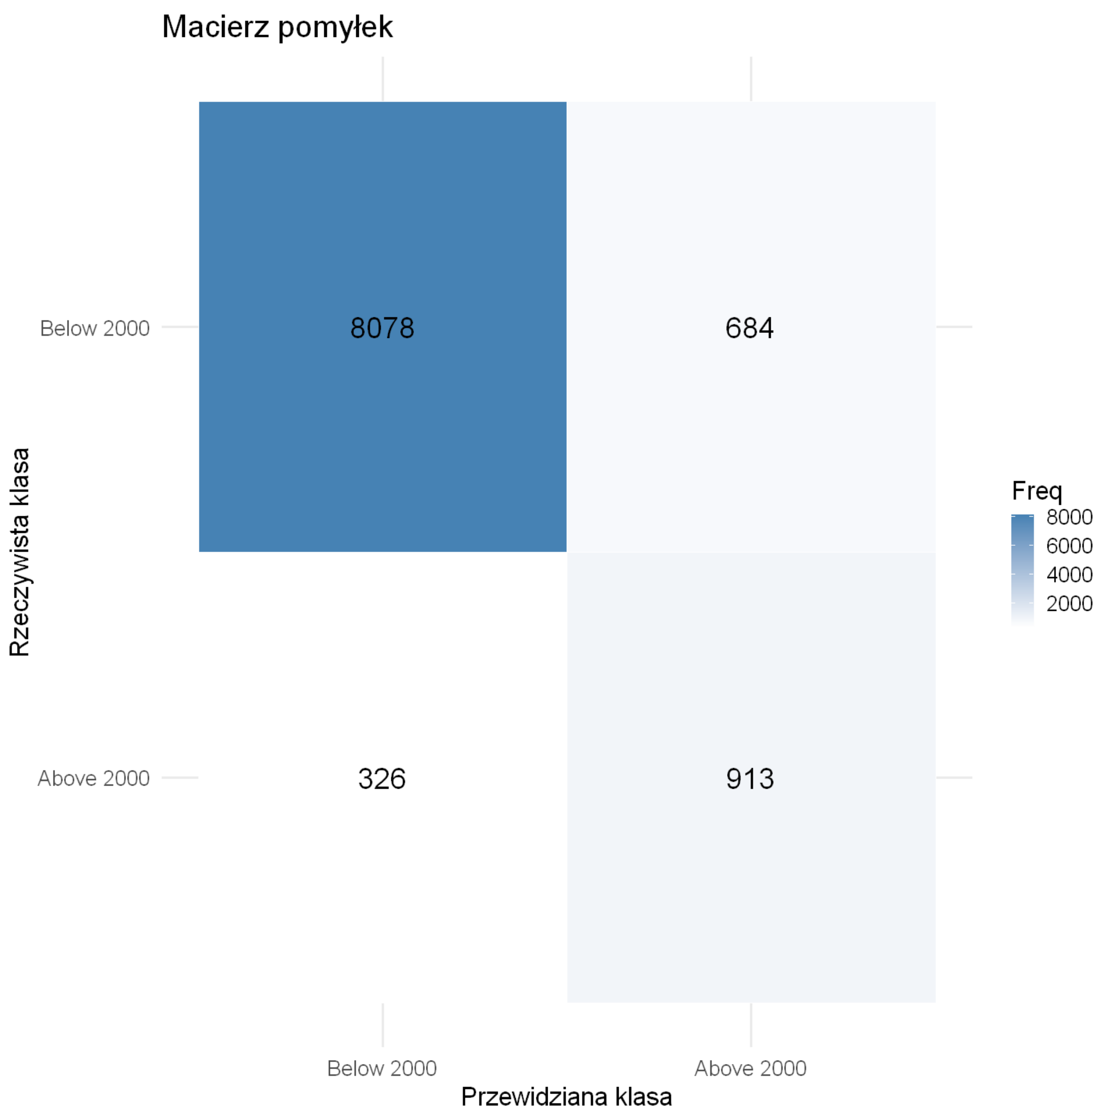

Model dosyć dobrze radzi sobie z predykcją właściwej klasy. Jeśli jednak już się myli, to częściej klasyfikuje graczy w rzeczywistości poniżej 2000 jako graczy powyżej 2000 rankingu.

[18]:
```
# A helper function for calculating and printing basic evaluation metrics
evaluate_confusion_matrix <- function(cm) {
  TP <- cm["Above 2000", "Above 2000"]
  FN <- cm["Above 2000", "Below 2000"]
  FP <- cm["Below 2000", "Above 2000"]
  TN <- cm["Below 2000", "Below 2000"]

  accuracy <- (TP + TN) / (TP + TN + FP + FN)
  precision <- TP / (TP + FP)
  recall <- TP / (TP + FN)
```

```
  f1 <- 2 * (precision * recall) / (precision + recall)

  cat("Accuracy:", round(accuracy, 4), "\n")
  cat("Precision:", round(precision, 4), "\n")
  cat("Recall:", round(recall, 4), "\n")
  cat("F1-score:", round(f1, 4), "\n")
}
```

[19]:
```
evaluate_confusion_matrix(dir_logistic$cm)
```

```
Accuracy: 0.899
Precision: 0.5717
Recall: 0.7369
F1-score: 0.6439
```

Model klasyfikacyjny osiągnął wysoką trafność (accuracy) na poziomie 89,9%, co oznacza, że poprawnie sklasyfikował większość przypadków. Precyzja wynosząca 57,2% wskazuje, że spośród graczy zaklasyfikowanych jako posiadających ponad 2000 elo, tylko nieco ponad połowa rzeczywiście spełnia ten warunek. Z kolei recall na poziomie 73,7% oznacza, że model dobrze wychwytuje graczy z wyższym poziomem, poprawnie identyfikując większość z nich. F1-score, będący średnią harmoniczną precyzji i recallu, wynosi 64,4% i pokazuje zrównoważoną skuteczność modelu w rozpoznawaniu klasy "Above 2000", choć jest jeszcze miejsce na poprawę, szczególnie w zakresie ograniczania liczby fałszywych trafień.

Dla celów porównawczych, przeprowadzamy teraz predykcję na zbiorze testowym, który nie był wykorzystywany podczas uczenia modelu:

[ ]:
```
dir_logistic_t <- list()
dir_logistic_t$fit <- dir_logistic$fit      # No need to repeat training process

dir_logistic_t$probs <- predict(dir_logistic_t$fit, data_test, type =␣
 ↪"response")
dir_logistic_t$predicted <- ifelse(dir_logistic_t$probs > 0.5, "Above 2000",␣
 ↪"Below 2000")

# Create confusion matrix
dir_logistic_t$cm <- table(dir_logistic_t$predicted, data_test$elo_category)
```

[26]:
```
plot_confusion_heatmap(dir_logistic_t$cm)
```

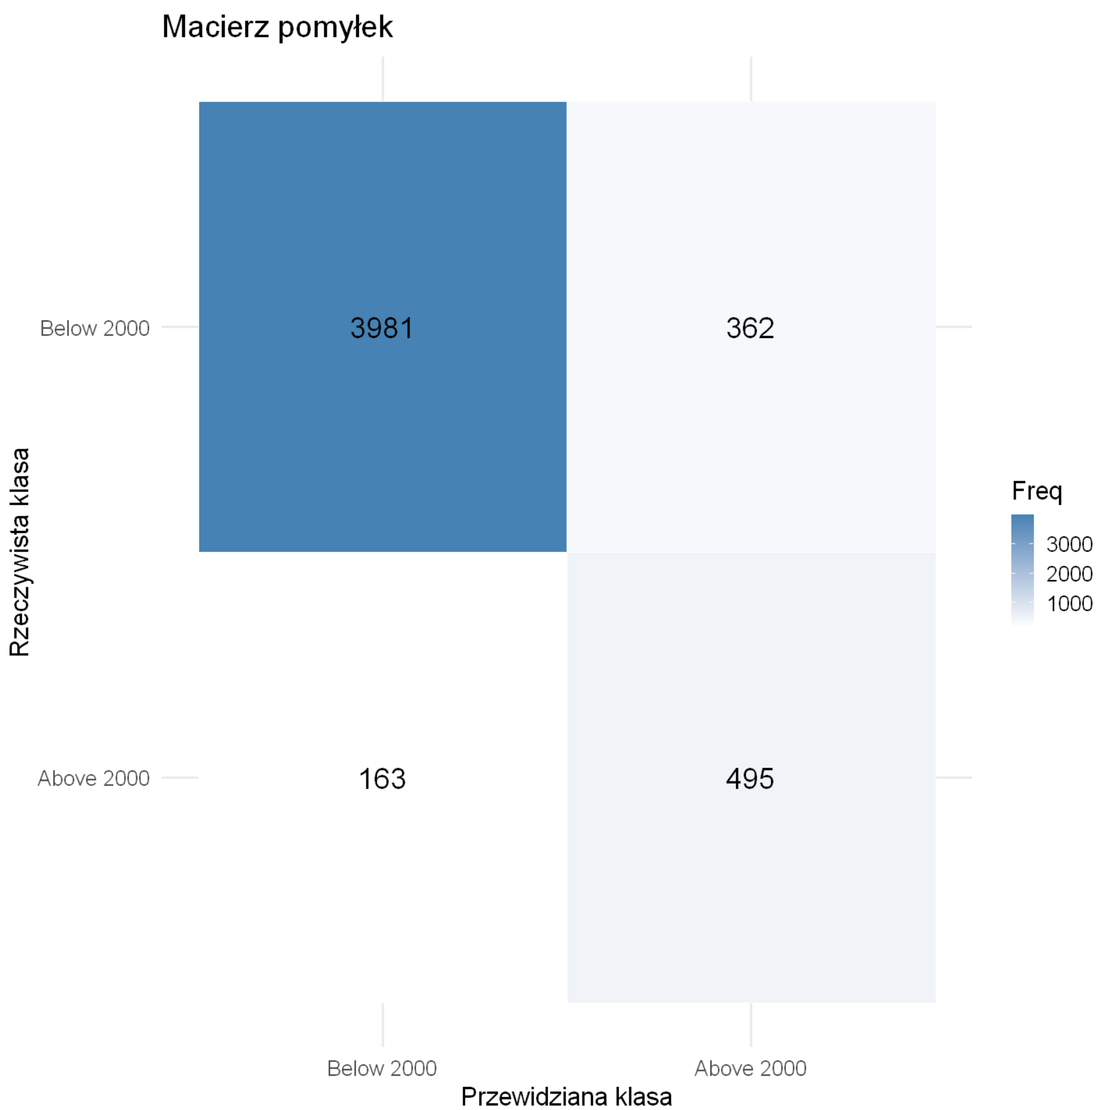

[27]:
```
evaluate_confusion_matrix(dir_logistic_t$cm)
```

```
Accuracy: 0.895
Precision: 0.5776
Recall: 0.7523
F1-score: 0.6535
```

Otrzymane wyniki dla zbioru testowego są zbliżone do tych dla zbioru treningowego. Oznacza to dobrą generalizację modelu.

Na koniec testujemy model regresji logistycznej wytrenowany z użyciem tylko dwóch najbardziej istotnych cech: `avg_cp_loss` i `avg_blund`:

[29]:
```
dir_logistic_best2 <- list()
dir_logistic_best2$fit <- glm(elo_category ~ avg_cp_loss + avg_blund,
                              family = binomial, data = data_train)

# Calculate probabilities and make predictions
dir_logistic_best2$probs <- predict(dir_logistic_best2$fit, data_test, type =
 ↪"response")
dir_logistic_best2$predicted <- ifelse(dir_logistic_best2$probs > 0.5, "Above
 ↪2000", "Below 2000")

# Create confusion matrix
dir_logistic_best2$cm <- table(dir_logistic_best2$predicted,
 ↪data_test$elo_category)
```

[30]:
```
plot_confusion_heatmap(dir_logistic_best2$cm)
```

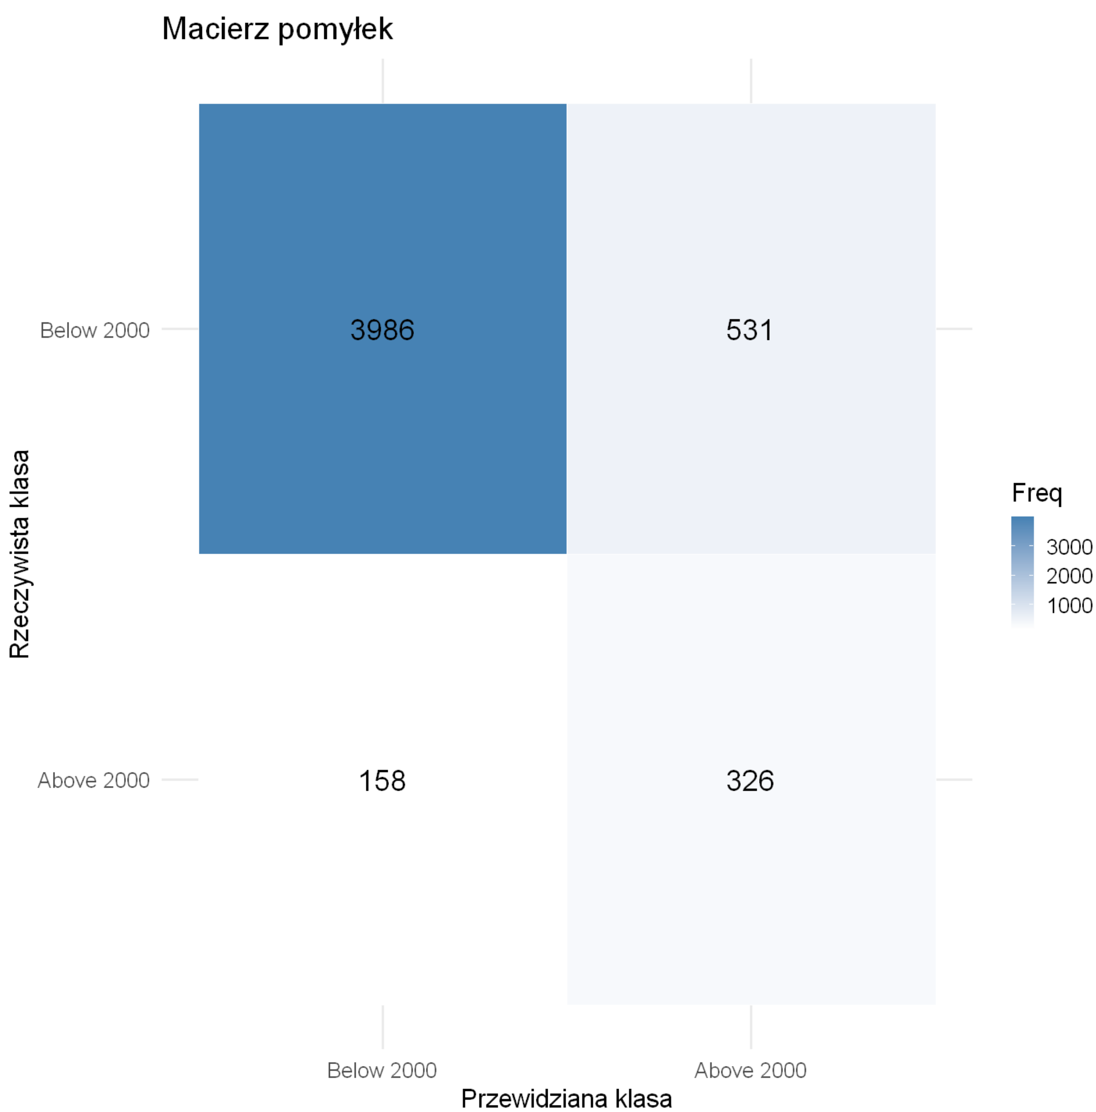

[32]:
```
evaluate_confusion_matrix(dir_logistic_best2$cm)
```

```
Accuracy: 0.8622
Precision: 0.3804
Recall: 0.6736
F1-score: 0.4862
```

Widzimy wyraźny spadek wartości metryk, zwłaszcza precyzji. Oznacza to pojawienie się znacznie większej liczby przypadków fałszywie pozytywnych (wzrost o ponad 46%, z 362 na 531). Ponieważ zbiór jest niezbalansowany i większość graczy posiada mniej niż 2000 punktów rankingowych, świadczy to o poważnym spadku skuteczności klasyfikatora i potwierdza zasadność użycia większej liczby cech w klasyfikacji.

3.5 LDA

[43]:
```
dir_lda <- list()
dir_lda$fit <- lda(elo_category ~ avg_cp_loss + avg_blund, data = data_train)

dir_lda$predicted <- predict(dir_lda$fit, data_test)

dir_lda$cm <- table(
  Predicted = dir_lda$predicted$class,
  Actual    = data_test$elo_category
)
```

[44]:
```
evaluate_confusion_matrix(dir_lda$cm)
```

```
Accuracy: 0.8516
Precision: 0.2007
Recall: 0.7511
F1-score: 0.3168
```

Wartość czułości (recall) wzrosła, jednak precyzja zanotowała znaczny spadek względem wyniku dla regresji logistycznej, co oznacza jeszcze więcej wyników fałszywie pozytywnych (tudzież graczy fałszywie sklasyfikowanych jako powyżej 2000 elo).

3.6 QDA

[49]:
```
dir_qda <- list()
dir_qda$fit <- qda(elo_category ~ avg_cp_loss + avg_blund, data = data_train)

dir_qda$predicted <- predict(dir_qda$fit, data_test)

dir_qda$cm <- table(
  Predicted = dir_qda$predicted$class,
  Actual    = data_test$elo_category
)
```

[50]:
```
evaluate_confusion_matrix(dir_qda$cm)
```

```
Accuracy: 0.8494
Precision: 0.4131
Recall: 0.5861
F1-score: 0.4846
```

Tym razem precyzja wzrosła, choć spadła czułość. Wynik wciąż jest jednak gorszy od regresji logistycznej dla dwóch zmiennych.

3.7 kNN

[56]:
```
data_train_selected <- data_train[, c("avg_cp_loss", "avg_blund")]
data_test_selected <- data_test[, c("avg_cp_loss", "avg_blund")]
```

[62]:
```
set.seed(410375)

ks <- c(1, 3, 5, 10)

for (k in ks) {
  preds <- knn(
    train = data_train_selected,
    test  = data_test_selected,
    cl    = data_train$elo_category,
    k     = k
  )

  cm <- table(
    Predicted = preds,
    Actual    = data_test$elo_category
  )

  cat(sprintf("kNN with k = %d:\n", k))
  cat("--------------------\n")
  evaluate_confusion_matrix(cm)
  cat("\n\n")
}
```

```
kNN with k = 1:
```

```
--------------------
Accuracy: 0.812
Precision: 0.4282
Recall: 0.4492
F1-score: 0.4385


kNN with k = 3:
--------------------
Accuracy: 0.8396
Precision: 0.4166
Recall: 0.5417
F1-score: 0.471


kNN with k = 5:
--------------------
Accuracy: 0.8454
Precision: 0.4154
Recall: 0.5669
F1-score: 0.4795


kNN with k = 10:
--------------------
Accuracy: 0.855
Precision: 0.4306
Recall: 0.6089
F1-score: 0.5044
```

Wyniki pokazują, jak zmieniają się podstawowe metryki klasyfikacji kNN w zależności od liczby sąsiadów k. Wraz ze wzrostem k dokładność (accuracy) modelu rośnie – od około 81,2% przy $k = 1$ do 85,5% przy $k = 10$, co sugeruje, że większa liczba sąsiadów pozwala na bardziej stabilne i trafne klasyfikacje. Jednak precyzja (precision) nie rośnie równomiernie i utrzymuje się na podobnym poziomie około 41–43%, co oznacza, że odsetek poprawnych pozytywnych klasyfikacji względem wszystkich przewidzianych pozytywnych jest umiarkowany. Z kolei recall (czułość) systematycznie wzrasta z 44,9% do 60,9%, co wskazuje, że model coraz lepiej wykrywa faktyczne przypadki pozytywne wraz ze wzrostem k. Podsumowując, najlepszy kompromis między precyzją a czułością osiągnięto dla $k = 10$, co potwierdza również najwyższy wynik F1-score (około 0,50). Oznacza to, że model przy $k = 10$ jest najbardziej efektywny w zrównoważonym wykrywaniu pozytywnych klas. Osiąga on zarazem porównywalną skuteczność co regresja logistyczna w wariancie z dwoma zmiennymi.